



ĐẠI HỌC QUỐC GIA TP.HCM – TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH

ĐỀ TÀI HỌC PHẦN MỞ RỘNG

TĂNG TỐC TÌM KIẾM GẦN ĐÚNG BẰNG THUẬT TOÁN **ScaNN** (*Scalable Nearest Neighbors*)

GVHD: Lê Thành Sách

Nhóm 16: Huỳnh Hoàng Anh | Ngô Trung Tín | Huỳnh Tấn Tiến

Mục Tiêu Đề Tài

Khám Phá ScaNN

Nghiên cứu sâu về thuật toán **Scalable Nearest Neighbors** của Google. Tìm hiểu cách ScaNN giải quyết bài toán tìm kiếm vector quy mô lớn với độ trễ thấp. Hiểu rõ 3 cơ chế lõi: *Phân vùng*, *Chấm điểm (AVQ)*, và *Sắp xếp lại*.

Hiện Thực & Ứng Dụng

Cài đặt thuật toán để giải quyết bài toán **MIPS** (Maximum Inner Product Search).


Áp dụng vào hệ thống thực tế như **GraphRAG** để cải thiện hiệu năng truy vấn thông tin trong các hệ thống AI hiện đại.

Kiến Trúc ScaNN: Phân Vùng

Nguyên lý cốt lõi: Thu hẹp không gian tìm kiếm từ $O(N)$ xuống dưới tuyến tính.

- Sử dụng thuật toán **K-means clustering** để chia tập dữ liệu thành các cụm (leaves).
- Tham số num_leaves: Quyết định độ mịn của phân vùng (thường là $ROWS/100$).
- **Đánh đổi:** Nhiều cụm (leaves) giúp lọc tốt hơn nhưng tốn chi phí duyệt; ít cụm giúp tìm nhanh nhưng giảm độ chính xác.

Vector Database



Unstructured data


0.2	-1.7	...	2.3
0.4	0.5	...	-1.7
4.1	-1.9	...	-1.5
-1.1	0.7	...	5.3
-3.5	2.3	...	0.5
-1.7	0.4	...	0.2
2.3	0.2	...	0.7
-1.9	4.1	...	-2.4
0.5	-1.5	...	2.3

Embeddings

Lượng Tử Hóa Vector Định Hướng (AVQ)

Điểm đột phá nhất của ScaNN so với các thuật toán khác (như Product Quantization truyền thống).

- ✓ **Vấn đề:** Lượng tử hóa thông thường giảm thiểu sai số tái tạo tổng thể, nhưng không tối ưu cho tích vô hướng (Dot Product).
- ✓ **Giải pháp AVQ:** Sử dụng hàm mất mát "nhận biết điểm số" (score-aware loss).
- ✓ **Cơ chế:** Chấp nhận sai số lớn ở hướng vuông góc, nhưng **phạt nặng sai số song song** với vector gốc.
- ✓ **Kết quả:** Bảo toàn độ chính xác cao cho các vector có tích vô hướng lớn (Top-K results).



Giai Đoạn Sắp Xếp Lại (Reordering)




Tìm Kiếm Tho

Sử dụng chỉ mục đã phân vùng và lượng tử hóa để tìm ra tập ứng viên tiềm năng lớn hơn yêu cầu (ví dụ: tìm 100 ứng viên cho Top-10).



Tính Toán Chính Xác

Tính tích vô hướng chính xác trên dữ liệu gốc (hoặc dữ liệu nén ít hơn) cho tập ứng viên này.



Top-K Cuối Cùng

Sắp xếp lại dựa trên điểm số chính xác và trả về K kết quả tốt nhất. Cân bằng hoàn hảo giữa Tốc độ và Recall.

So Sánh Các Thuật Toán ANN

Thuật toán	Nguyên lý	Độ chính xác	Tốc độ	Khả năng mở rộng
Brute Force	Tính tất cả khoảng cách	100% (Tuyệt đối)	Rất chậm ($O(N)$)	Kém
Annoy (Spotify)	Random Projection Trees	Trung bình	Nhanh	Trung bình
FAISS (Meta)	Clustering + PQ	Cao	Rất nhanh (GPU)	Lớn
HNSW	Đồ thị nhiều tầng	Rất cao	Cực nhanh	Lớn (tốn RAM)
ScaNN (Google)	Partition + AVQ + Reorder	Rất cao	Cực nhanh	Rất lớn (Tỷ vector)

* ScaNN vượt trội nhờ tối ưu hóa đặc biệt cho các embedding từ mô hình học máy hiện đại.



Quy Trình Thực Hiện

1. Thu Thập

Crawl dữ liệu tin tức từ RSS
(VnExpress, Tuổi Trẻ...).

2. Embedding


Sử dụng mô hình
Vietnamese-SBERT để chuyển
văn bản thành vector 768 chiều.

3. Indexing

Xây dựng chỉ mục ScaNN:
Partitioning (32 leaves), AVQ
(threshold 0.25).

4. Search

Truy vấn Top-K với Reordering
(100 -> 10) và đánh giá hiệu
năng.



Kết Quả Thực Nghiệm Chi Tiết

Top-K	Thời gian Brute-force (s)	Thời gian ScaNN (s)	Tăng tốc (Speed-up)	Recall@K
10	0.002436	0.000446	5.46x	0.9740
20	0.002330	0.000429	5.44x	0.9733
50	0.002279	0.000417	5.46x	0.9659
100	0.002313	0.000440	5.26x	0.8827

⚡Hiệu Năng


Tốc độ truy vấn ổn định ở mức tăng tốc ~5.4x bất kể Top-K thay đổi, chứng tỏ khả năng mở rộng tốt của ScaNN.

🎯Độ Chính Xác



Recall duy trì ở mức rất cao (>96%) cho K nhỏ. Khi K=100, Recall giảm nhẹ xuống 88.27% do giới hạn của không gian tìm kiếm xấp xỉ.





Kết Quả Thực Nghiệm Chi Tiết



Kết Quả Thực Nghiệm Chi Tiết: $N=4,000,000$, Mem~2GB



Kết Quả Thực Nghiệm Chi Tiết



Kết quả demo tìm kiếm

DEMO TÌM KIẾM TIN TỨC VIỆT NAM (ScaNN)

🔍 Tìm kiếm: AI ở Việt Nam

Tìm ngay

Đang tìm: 'AI ở Việt Nam'...

🕒 Tìm thấy 10 kết quả trong 13.54 ms

1. Công nghệ mở là con đường để Việt Nam làm chủ AI <https://vnexpress.net/cong-nghe-mo-la-con-duong-de-viet-nam-lam-chu-ai-4959512.html>
(Score: 29.0999)
2. Sẽ xây dựng trung tâm siêu tính toán để phát triển AI Việt Nam <https://vnexpress.net/se-xay-dung-trung-tam-sieu-tinh-toan-de-phat-trien-ai-viet-nam-4986944.html>
(Score: 28.9229)
3. Google: 81% người Việt tương tác với AI hàng ngày <https://vnexpress.net/google-81-nguoi-viet-tuong-tac-voi-ai-hang-ngay-4985885.html>
(Score: 28.6627)
4. Châu Âu đánh giá cao tiềm năng phát triển AI của Việt Nam <https://vnexpress.net/chau-au-danh-gia-cao-tiem-nang-phat-trien-ai-cua-viet-nam-4956510.html>
(Score: 28.0932)
5. 'Việt Nam nên phát triển AI có chủ quyền' <https://vnexpress.net/viet-nam-nen-phat-trien-ai-co-chu-quyen-4956984.html>
(Score: 25.7700)
6. Con khát nhân lực AI Việt <https://vnexpress.net/con-khat-nhan-luc-ai-viet-4955480.html>
(Score: 25.1370)
7. Nhóm học sinh Việt phát triển AI làm trợ lý học tập <https://vnexpress.net/nhom-hoc-sinh-viet-phat-trien-ai-lam-tro-ly-hoc-tap-4964410.html>
(Score: 24.7219)

Hạn chế của tìm kiếm cơ bản



Chỉ Xét Tiêu Đề

Hệ thống chỉ thực hiện vector hóa và tìm kiếm hóa và tìm kiếm dựa trên tiêu đề bài viết, bỏ qua nội dung chi tiết.



Thiếu Ngữ Nghĩa Sâu

Không nắm bắt được ngữ cảnh toàn văn bản (full-text context), dẫn đến việc bỏ sót thông tin quan trọng.



Khả năng Suy luận kém


Chỉ tìm kiếm dựa trên độ tương đồng bề mặt (similarity matching).

Mở Rộng: Kiến Trúc GraphRAG

Vấn đề của RAG truyền thống: Mất mát ngữ cảnh và thiếu khả năng suy luận đa bước.

Giải pháp GraphRAG tích hợp ScaNN:

- Sử dụng ScaNN làm bộ máy truy vấn lai (Hybrid Retrieval).
- Kết hợp tìm kiếm ngữ nghĩa (Vector Search) với cấu trúc tri thức (Knowledge Graph).
- Giải quyết các bài toán về thực thể và quan hệ ẩn.



Tối Ưu Hóa 6 Vấn Đề Cốt Lõi



Strategic Chunking

Dùng vector similarity để gộp câu có cùng ngữ nghĩa, tránh cắt đoạn vô lý.



Entity Disambiguation

Gom nhóm các tên gọi khác nhau của cùng 1 thực thể (Vd: Da Vinci = Leonardo).



Link Prediction

Phát hiện quan hệ ẩn giữa các nút dựa trên độ tương đồng vector > 0.90 .



Fuzzy Node Lookup

Tìm nút đồ thị ngay cả khi người dùng gõ không chính xác tên thực thể.



Reference Tracking

Truy vết ngược từ Node về đoạn văn bản gốc (Chunk) để trích dẫn nguồn.




Short-term Memory

Cache câu hỏi tương tự để trả lời nhanh mà không cần tính toán lại.

Tối Ưu Hóa 6 Vấn Đề Cốt Lõi


Problem #1

Sử dụng ScaNN cho việc chunk có chiến thuật



Problem #2


Sử dụng ScaNN để gộp những Node có chung ý nghĩa



Tối Ưu Hóa 6 Vấn Đề Cốt Lõi

Problem #3

Sử dụng ScaNN để làm giàu mối quan hệ giữa các Node



Problem #4

Sử dụng ScaNN để hỗ trợ graph tìm kiếm nhanh Node



How Graph find node?

If you type "Davinci", the graph can immediately access the index to find adjacent nodes.

But if you type "Who is Davinci?", graph will find node "Who is Davinci?" It can't find that node!

We can use LLM to parse sentences but it is not fast and very resource intensive.

Therefore, we apply ScaNN to assist Graph in finding nodes.




Tối Ưu Hóa 6 Vấn Đề Cốt Lõi

Problem #5

Sử dụng ScaNN để tìm nguồn trích dẫn

How Graph find reference?

When the graph starts to expand node, the next will be the input of the ScaNN to find the reference of the information




Problem #6

Dùng ScaNN để phát hiện những câu hỏi tương tự

Similar question ?

If a user asks a similar question, a model without short-term memory must recompute everything from scratch to generate an answer. To overcome this limitation, our team implemented a short-term memory mechanism that allows the model to quickly retrieve semantically similar questions using ScaNN, enabling much faster responses.



Kết Luận

- ✓ **Hiệu năng vượt trội:** ScaNN chứng minh khả năng tăng tốc 5x so với Brute-force với độ chính xác gần như tuyệt đối, phù hợp cho hệ thống Big Data.
- ✓ **Công nghệ lõi:** Sự kết hợp giữa Partitioning và Anisotropic Vector Quantization (AVQ) là chìa khóa cho sự thành công của thuật toán.
- ✓ **Tính ứng dụng cao:** Không chỉ dừng lại ở tìm kiếm, ScaNN đóng vai trò xương sống trong việc tối ưu hóa các hệ thống AI phức tạp như GraphRAG.
- ✓ **Hướng phát triển:** Tiếp tục tích hợp với các mô hình ngôn ngữ lớn (LLM) để xây dựng hệ thống hỏi đáp thông minh thời gian thực.

Lời kết

Cảm ơn Thầy và các bạn đã lắng nghe!



Mã nguồn demo: github.com/hoanganh1105/scann-approximate-nearest-neighbor